

软件设计说明书

版本变更历史

版本	变更时间	修改人	修改章节	备注
1.0	2024/4/29	孙烨	确定整体结构	初稿
1.1	2024/5/10	孙烨、曾祥华	1, 2	引言、设计概述、软件总体设计
		窦建玲、刘顺博	4	标注子系统详细设计
		魏家龙、郭鑫	5	挖掘子系统详细设计
		苏丁力	3, 6	界面设计

参考说明书：[Sign in](#)

参考ppt:

-  [软件工程 G组 第七周 v2.1.pptx](#)
-  [软件工程 G组 第八周 v2.0.pptx](#)
-  [软件工程 G组 第十周 v3.0.pptx](#)

1 引言

1.1 系统概述

智能文本标注系统（ITAS）旨在为系统标注管理员、数据标注员和科研人员提供一个强大的工具，以高效、准确地处理和分析大量文本数据。系统由两个紧密相连的子系统组成：文本标注子系统和智能挖掘子系统，它们共同服务于三类主要用户——系统标注管理员、数据标注员和科研人员。

- 文本标注子系统作为智能挖掘子系统的前驱，提供一个用户友好的界面和工具集，协助研究人员高效准确地进行科学文献中段落和实体的标注，通过预设的标注规则，大幅降低标注工作的难度和时间成本，提高标注数据的准确性和一致性，并将标注结果提供给挖掘子系统。
- 智能挖掘子系统则扩展和应用这些数据，利用先进的大语言模型和自然语言处理技术识别和提取未标注文本中预定义的信息。模型支持小样本学习，以适应数据稀缺的研究场景，从而提高从大量未标注文本中快速准确提取信息的能力。

1.2 编写目的

该文档的设计是为了让智能文本标注系统的开发人员明确各阶段的任务需求和开发进度，便于开发人员之间相互交流，相互合作，完成开发任务。在保证可完成性的情况下，尽可能详细地约定各个模块的实现细节，记录项目落实过程中的各种方案思路和决策意见。另一方面，在后续的软件测试阶段，测试人员还可参考此文档完成测试任务。

1.3 文档范围

该设计文档的使用范围为整个工程开发的全部阶段，包括：背景调研阶段、需求分析阶段、产品设计阶段、系统开发阶段、性能优化阶段、软件测试阶段和最终发布阶段，每个阶段都根据设计文档逐步推进。背景调研阶段确定项目内容，着手设计文档的框架搭建；需求分析和产品设计阶段对系统的最终完成版进行构想并提出可能实现的功能，在后续开发过程中根据实际情况不断进行迭代修改；系统开发阶段按照之前提出的功能设计分模块按步骤有序完成；性能优化阶段按照已有的初级系统，结合设计文档和实际需求对各个功能进行优化；软件测试阶段按照设计文档就曾经提出来并已实现的功能进行系统测试，并提出意见供相关开发人员修改；最终发布阶段完善设计文档，并按照预期时间发布软件。

1.4 读者对象

该文档的读者范围为智能文本标注系统团队全体成员（乙方）和课程专家组人员（甲方）。

1.5 术语与缩略语解释

本系统设计过程中涉及的一些专业术语以及缩略语如下表1.1所示。

表1.1 术语与缩略语解释

术语/缩略语	解释
Spring Boot	Spring Boot是一个开源的Java框架，用于简化Spring应用的创建和部署。它提供了置、自动配置的功能，让开发者能够快速启动和运行Spring应用。Spring Boot适用境，使得创建独立的、生产级别的Spring基础的应用程序变得更加容易。
Spring Cloud	Spring Cloud是基于Spring Boot的一套微服务工具，提供了在分布式系统中常见模配置管理、服务发现、断路器、智能路由、微代理、控制总线、全局锁、领导选举和等。它适合开发常见的分布式系统和微服务架构。
Vue	Vue是一个渐进式JavaScript框架，用于构建用户界面。其核心库专注于视图层，易他库或现有项目。Vue是完全可扩展的，可以通过添加插件和组件来逐渐适应更复杂
Docker	Docker是一个开源的应用容器引擎，让开发者可以打包应用以及依赖包到一个轻量:器中，然后这个容器可以在任何机器上运行，也易于系统的持续集成工作流的集成。
Nginx	Nginx是一个高性能的HTTP和反向代理服务器，也是一个IMAP/POP3/SMTP服务器性能、稳定性、丰富的功能集、简单的配置和低资源消耗而闻名。
MinIO	MinIO是一个高性能的分布式对象存储服务，可以存储大量非结构化数据，如图片、兼容Amazon S3云存储服务的API，支持水平扩展，适用于构建现代数据基础设施的
MySQL	MySQL是一个关系型数据库管理系统，由瑞典MySQL AB公司开发，属于Oracle旗7流行的关系型数据库管理系统之一，在Web应用领域有着举足轻重的地位。开发者可 对系统中的各种数据进行维护管理。
Redis	Redis是一个开源的键值对数据库，通常被用作数据结构服务器。它支持多种类型的串、哈希、列表、集合、带范围查询的有序集合等。Redis具有内存数据集和持久化现缓存、消息队列等功能。
GPT	GPT（Generative Pre-trained Transformer）是一个基于深度学习的自然语言处理练和微调的方法来处理各种语言理解和生成任务。它的架构基于Transformer，能够 关性高的文本。
BERT	BERT（Bidirectional Encoder Representations from Transformers）是一种预训法，用于自然语言处理（NLP）任务。它通过在大规模文本语料库上训练，学习文不示，然后可以用于各种NLP任务的微调。

1.6 参考文献

[1] GB/T 9385-2008,计算机软件需求规格说明规范[S]. 北京:中国标准出版社,2008.

[2] GB/T 8567-2006,计算机软件文档编制规范[S].北京:中国标准出版社,2006.

2 设计概述

2.1 需求概述


ITAS系统面向三类主要用户——系统标注管理员、数据标注员和科研人员，每种角色具有独特的需求和特点。通过明确的角色定义和职责分配，以及针对不同角色的功能设计，确保系统能够满足各类用户

的特定需求。

- 系统标注管理员通常是科研机构、大学和企业的代表，他们需要高质量的数据支持科研工作。作为标注和抽取全过程的核心角色，管理员不仅定义标注预设、上传文档、管理标注项目，还负责导出标注数据并参与模型的训练和验证。此外，管理员在遇到无法满足现有研究需求的预设时，还需创建新的预设并参与后续的标注和抽取工作，显示出对系统灵活性和全面性的高需求。
- 数据标注员角色可能由专业的数据标注团队或领域内的研究人员和学生担任。他们主要负责执行具体的文档标注任务，需要高效、直观的工具来完成大量文本标注，依赖于系统提供的清晰指示和预设。标注员对工具的易用性和标注效率有着极高的要求，但可能缺乏进行深入标注所需的领域知识。
- 科研人员，包括研究人员、科学家、技术人员及数据分析师等，主要使用智能挖掘子系统，利用系统提取和挖掘文献中的关键信息。他们侧重于系统的智能化能力，期望通过最小的人工干预获得最大的信息价值，对系统的自动化和智能化水平有较高的期望。

此外，用户可能需要在不同角色之间切换，体现了系统设计需要支持灵活的角色管理和任务切换能力。例如，一个用户可能初期作为系统标注管理员定义新的预设，随后作为数据标注员参与标注工作，最终转为科研人员使用预设进行信息抽取。这种多角色的用户特点要求系统不仅要提供针对各个角色的定制化功能，还要确保不同角色间能够无缝衔接，以满足用户在不同研究阶段的需求。

2.2 需求与功能的对应关系



系统	一级需求	参与用户	二级需求	功能设计
文本标注子系统	用户注册登录	数据标注员	未注册用户注册	提供注册新用户功能，支持密码强度验证。
		标注管理员/数据标注员	已注册用户登录	提供用户登录功能，支持忘记密码找回。
	标注项目创建	标注管理员	上传标注文档	创建两类标注任务（标注任务、标注规则），定义标注规则，指定一个或多个标注员，并分配标注任务。
		标注管理员	指定标注规则	
		标注管理员	分派标注任务	
	标注项目管理	标注管理员	审核标注结果	审核标注项目的完成情况，计算薪酬。
		标注管理员	查看任务量报表	
		标注管理员	标注数据导出	
	标注任务执行	数据标注员	段落标注提取	依据界面引导学习平台标注规则完成分配给自身的标注任务。
		数据标注员	关键信息标注	
智能挖掘子系统	挖掘模型上传	科研人员	科研人员模型上传	为满足部分无模型训练需求，本系统提供在线训练特定领域的挖掘模型，供用户选择。
	挖掘模型选择	科研人员	社区共享模型	提供三种模型选择：社区共享模型，且F1指标大于0.8；预设模型调用，直接调用系统内置模型；第三方接口调用，直接调用第三方接口。
		科研人员	预设模型调用	
		科研人员	第三方接口调用	
	挖掘文档上传	科研人员	文献数据上传	选择并上传待标注文档，若文档符合要求，则自动执行挖掘。
	目标信息挖掘	科研人员	目标段落提取	根据选择的挖掘模型提取目标信息。系统首先提取段落信息，再根据提取的段落信息提取关键标注数据。
		科研人员	关键信息提取	

3 系统总体设计

本节概述了智能文本标注系统（ITAS）的总体设计以及功能模块划分和描述。

3.1 系统架构



图 2-2 ITAS系统架构图

本章节详细介绍智能文本标注系统（ITAS）的系统架构系统，整体架构如下图3.1所示。该架构采用了前后端分离的技术实现，集成了现代Web技术和机器学习模型，以支持文本数据的高效标注和处理。

ITAS前端使用Vue.js作为主框架，结合Ant Design提供丰富且直观的用户界面。系统通过vue-router管理前端路由，确保应用的单页特性与用户界面状态的一致性。此外，前端通过Axios库与后端进行异步数据交互，实现了一个响应迅速且用户友好的操作环境。

后端架构基于Spring Boot和Spring Cloud，构建了一个微服务架构的后台应用。Spring Boot提供了极大的便利性和灵活性，使得后端服务的开发、部署和扩展变得简单高效。Spring Cloud为我们的服务间通信提供了一系列解决方案，如服务发现、配置管理和负载均衡等。Nginx作为反向代理服务器，在系统中承担着负载均衡和请求转发的角色。我们的数据操作依托于Mybatis框架，以支持复杂的数据库交互。

数据存储层采用MySQL作为主要的结构化数据存储方案，负责存储用户数据和标注信息。Minio提供对象存储服务，用于存储文本和其他非结构化数据。Redis则被用作缓存系统，提高数据访问的速度和系统的响应能力。

标注模型部分集成了基于BERT的段落定位技术和GPT API的实体标注功能。BERT模型用于理解和分析文本内容，有效地定位相关段落，而GPT API则在这些定位的段落中进行实体识别和标注。这种结合使用的方式极大地提升了标注的准确性和效率，使得ITAS平台在处理大规模文本数据时表现出色。

我们还利用了RabbitMQ来处理系统间的消息队列，确保了高效的数据流和任务执行。Docker容器化技术则用于部署各个服务，保证了环境的一致性和系统的可移植性。通过这样的系统架构设计，智能

文本标注系统能够提供稳定、高效、可扩展的服务，满足现代数据处理和分析的需求。

3.2 数据设计

系统总体数据流图如下图2-3所示。




图 2-3 数据流图

数据字典如下：

标注：在文本数据中识别并显式地标记出特定信息或实体的过程。标注既是为了人类理解而明确标出文本特定部分的行为，也是为了机器学习模型训练提供示例的准备工作。标注的目的是通过明确示范，使模型能够学习如何自动识别和处理相似的文本信息。

抽取：利用经过训练的模型自动从文本中识别并提取出预定义实体或信息的过程。抽取是标注工作的延伸和应用，通过自动化方法实现对大量未标注文本中相同类型信息的识别和提取。

标注数据集：一组已经手工标注好的文本数据，其中明确标识了待抽取实体的位置和类别。标注数据集是机器学习模型训练过程中的关键输入，用于教导模型识别和理解文本中的特定信息。以发票数据抽取为例，标注数据集包括指出发票文本中的供应商、发票号码、金额等实体字段的样本。

段落：文本中按照逻辑、主题或格式分隔的连续句子组。在文档结构中，段落作为基本单位，承载特定的信息或论点。

实体：文本中可以独立存在的、有明确指代的对象，包括但不限于人名、地名、机构名、时间、事件、数字等。实体在文本挖掘中通常作为信息抽取和分析的基础单位。

模型：通过机器学习技术构建的算法，旨在自动化执行文本的标注和抽取任务。模型基于训练数据学习识别文本中的特定段落或实体，能够应用于未知文本的自动处理。随着大语言模型的流行，传统模型逐渐被如GPT等LLM模型取代。

- 段落模型：专门用于处理和理解文本中特定段落或内容类型的机器学习模型。段落模型如BERT能够捕捉文本中的深层语义关系，适用于理解整个文档结构和内容。这类模型通常用于分析文档的大块文本，如摘要、引言或结论等。
- 实体模型：专门用于识别和提取文本中的具体实体（如人名、地名、日期、事件等）的机器学习模型。实体模型如LSTM（长短期记忆网络）CRF（条件随机场）和StructBert（结构化BERT），通过理解文本的局部上下文来识别特定的信息点。这些模型擅长处理细粒度的任务，如命名实体识别（NER）。

预设：一套预定义的规则和模板，旨在指导标注和抽取过程中的实体识别、分类及相关属性的提取。预设框架确保了信息处理的一致性和高效性，可根据不同的应用场景进行定制。

- 段落预设：专为处理和分析文档中特定段落或内容类型而设定的一系列预设规则。这些规则指导如何标注和抽取文档的结构性部分（如摘要、引言、结论等），旨在提高特定信息抽取的准确度和效率。

实体预设：针对需从文档中识别和抽取的特定实体类型（如人名、地名、日期、事件等）而设定的一系列预设规则。实体预设旨在提高从大量文本中快速、准确地标注和抽取关键信息的效率和准确度。

3.3. 技术选型

为确保ITAS能够高效、稳定且可扩展地运行，本项目包括前端、后端、数据存储、标注模型、基础服务五大部分：

前端

- 框架：采用 Vue 3.0 框架，利用其组合式 API 和响应式系统提高开发效率和用户界面的响应性。
- 路由管理：使用 vue-router 来管理前端路由，确保页面的正确加载和优化用户导航体验。
- 状态管理：使用 Pinia 作为全局状态管理库，提供更简洁和强大的状态管理功能，易于维护和扩展。
- UI 组件库：选用 Ant-Design-Vue，因其提供广泛的设计美观且功能丰富的 Vue 组件，加速开发流程。
- 数据交互：使用 Axios 作为 HTTP 客户端，处理与后端的数据交换。

后端

- 微服务框架：采用 Spring Cloud，提供全面的微服务支持，包括服务发现、配置管理、消息路由等。
- 网关与安全：使用 Spring Gateway 作为网关，结合 Spring Security 进行用户认证和授权，保障数据安全。
- 应用结构：应用 Spring MVC 框架进行系统架构划分，优化处理流程。
- ORM 数据操作：使用 Mybatis / Mybatis Plus 进行数据库操作，提高开发效率和SQL语句的复用。

数据存储

- 结构化数据：选用 MySQL，提供稳定且成熟的关系数据库管理系统。
- 文件对象存储：采用 Minio，支持高效的对象存储解决方案。
- 缓存数据：使用 Redis，提升数据访问速度，优化性能。

标注模型

标注模型：基于训练数据学习识别文本中的特定段落或实体，能够应用于未知文本的自动标注和抽取。




- 段落模型：用于处理和理解文本中特定段落或内容类型的机器学习模型，使用BERT模型。该模型擅长双向上下文理解，适合上下文依赖的复杂任务（如段落理解）。
- 实体模型：用于识别和提取文本中的具体实体（如人名、地名、日期、事件等），使用GPT模型。该模型擅长单向文本生成，有优秀的文本续写和对话生成能力，在实体识别方面达到很高的准确度。

基础服务

- 腾讯云：在腾讯云服务器上部署项目，并注册域名方便公开访问。
- Docker：使用 Docker 容器化技术封装机器学习和高通量计算等算法引擎及软件工具，提高系统的可部署性和可移植性。
- RabbitMQ：部署 RabbitMQ 消息队列处理文件转换等异步任务，减少系统延迟，提高响应速度。

通过这一系列技术选型，我们期望构建一个灵活、高效且易于扩展的平台，满足研发过程中各类数据处理和算法计算的需求。

3.4 开发软件及流程



项目的有效管理依赖于多种工具，如Gitee进行代码同步，腾讯云提供稳定的运行环境。我们还使用了MySQL Workbench进行数据库管理、飞书进行文档管理、Postman进行接口测试，确保数据管理和团队协作的高效流畅，为项目的顺利进行提供了强有力的支持。开发流程包括以下步骤：

- 本地【开发环境】：连接云数据库本地开发
- Gitee【开发版本同步】：各模块开发代码上传及合并到相应gitee仓库
- 腾讯云服务器【正式&测试环境】：只允许Pull Master分支下的代码，不允许修改代码
- Gitlab【测试版本同步】：测试无误的代码上传，版本发布

4 标注子系统详细设计

4.1 系统类图




图3.1 系统Service层类图

Entity Relationship Diagram




图3.2 系统Entity层类图




图3.3 系统Controller层类图




图3.4 系统时序图

4.2 标注子系统功能设计

4.2.1 标注员管理(AnnotationController)

功能整体概述：

标注员管理支持添加标注员，删除标注员，根据项目id查看该项目的所有标注员功能。

涉及类详细介绍：

标注员管理功能主要涉及类的方法的详细介绍如表4.1所示。

表4.1 标注员管理功能主要涉及类方法

涉及类/接口	方法	说明
AnnotationContr oller	public ResultModel<List<String>> addAnnotator(	添加标注员
	public ResultModel<List<String>> removeAnnotat	删除标注员
	public ResultModel<List<String>> getAllAnnotato	根据项目id查看该项目的所

4.2.2 文件管理(FileController)

功能整体概述：

文件管理功能支持文件下载功能。

涉及类详细介绍：

文件管理功能主要涉及类的方法的详细介绍如表4.2所示。

表4.2 文件管理功能主要涉及类方法详细介绍

涉及类/接口	方法	说明
FileController	public ResponseEntity<byte[]> getHtmlFile(@Req	文件下载

4.2.3 标签管理(LableController)

功能整体概述：

标签管理支持创建标签，编辑标签，删除标签，根据任务id查询标签，根据文献id查询标签功能。

涉及类详细介绍：

标签管理功能主要涉及类的方法的详细介绍如表4.3所示。

表4.3 标签管理功能主要涉及类方法

涉及类/接口	方法	说明
LableController	public ResultModel<Label> createLabel(@Reques	创建标签
	public ResultModel<Boolean> editLabel(@Reque	编辑标签
	public ResultModel<Boolean> deleteLabel(@Req	删除标签
	public ResultModel<List<Label>> listByTask(@Re	根据任务id查询标签
	public ResultModel<List<Label>> listByPaper(@R	根据文献id查询标签

4.2.4 登录(LoginController)

功能整体概述：

登录功能支持用户登录，用户注册，用户退出，查看个人信息功能。

涉及类详细介绍：

登录功能主要涉及类的方法的详细介绍如表4.4所示。

表4.4 登录功能主要涉及类方法

涉及类/接口	方法	说明
LoginController	public ResultModel<String> login(@RequestParar	用户登录
	public ResultModel<Boolean> register(@Request	用户注册
	public ResultModel<Boolean> usernameExist(@R	用户退出
	public ResultModel<User> getProfile()	查看个人信息

4.2.5 文献管理(PaperController)

功能整体概述：

文献管理支持上传文献，删除文献，查看文献，根据项目id查询文献功能。

涉及类详细介绍：

文献管理功能主要涉及类的方法的详细介绍如表4.5所示。

表4.5 文献管理功能主要涉及类方法

涉及类/接口	方法	说明
PaperController	public ResultModel<Void> uploadPaper(@RequestPa	上传文献
	public ResultModel<Boolean> removePaper(@Re	删除文献
	public ResultModel<Paper> getByld(@RequestPa	查看文献
	public ResultModel<List<Paper>> listByProject(@	根据项目id查询文献

4.2.6 标注项目管理(ProjectController)

功能整体概述：

标注项目管理支持创建标注项目，更新标注项目，查看所有标注项目列表，查看我的标注项目列表，更新简介，根据id查询项目功能。

涉及类详细介绍：

标注项目管理功能主要涉及类的方法的详细介绍如表4.6所示。

表4.6 标注员管理功能主要涉及类方法

涉及类/接口	方法	说明
ProjectController	public ResultModel<Project> createProject(@Req	创建标注项目
	public ResultModel<Void> updateProject(@Reque	更新标注项目
	public ResultModel<PageModel<Project>> pageAl	查看所有标注项目列表
	public ResultModel<PageModel<Project>> pageM	查看我的标注项目列表
	public ResultModel<OssFile> uploadInstruction(@	更新简介
	public ResultModel<Project> getByld(@RequestP	根据id查询项目

4.2.7 结果返回(ResultExportController)

功能整体概述：

结果返回支持结果返回功能。

涉及类详细介绍：

结果返回功能主要涉及类的方法的详细介绍如表4.7所示。

表4.7 结果返回功能主要涉及类方法

涉及类/接口	方法	说明
ResultExportCont	public void exportResult(@RequestParam String p	结果返回

4.2.8 标记管理(TagController)

功能整体概述：

标记管理支持添加标记，查看标记，修改标记，删除标记功能。

涉及类详细介绍：

标记管理功能主要涉及类的方法的详细介绍如表4.8所示。

表4.8 标记管理功能主要涉及类方法

涉及类/接口	方法	说明
TagController	public ResultModel<Tag> createTag(@RequestPar	添加标记
	public ResultModel<List<Tag>> listTags(@Reques	查看标记
	public ResultModel<Void> updateTag(@RequestP	修改标记
	public ResultModel<Void> deleteTags(@RequestE	删除标记

4.2.9 任务管理(TaskController)

功能整体概述：

任务管理支持任务分配，数据统计，查看所有任务，查看我都任务，根据id查询任务，标记已完成任务功能。

涉及类详细介绍：

任务管理功能主要涉及类的方法的详细介绍如表4.9所示。

表4.9 任务管理功能主要涉及类方法

涉及类/接口	方法	说明
TaskController	public ResultModel<Boolean> assignTask(@Requ	任务分配
	public ResultModel<ProjectStatisticVO> getProjec	数据统计
	public ResultModel<PageModel<Task>> pageAllTa	查看所有任务
	public ResultModel<PageModel<Task>> pageMyTa	查看我都任务
	public ResultModel<Task> getById(@RequestPara	根据id查询任务
	public ResultModel<Boolean> changeFinished(@	标记已完成任务功能

4.2.10 用户管理(UserController)

功能整体概述：

用户管理支持查看用户信息功能。

涉及类详细介绍：

用户管理功能主要涉及类的方法的详细介绍如表4.10所示。

表4.10 用户管理功能主要涉及类方法

涉及类/接口	方法	说明
UserController	public ResultModel<PageModel<User>> page(@R	查看用户信息

4.3 数据库设计

4.3.1 概念结构设计

标注子系统共有五类实体，分别是用户、标注项目、文档、标签、标注结果。

用户实体包含两种身份：管理员、标注员。其属性包含用户ID、用户名、用户真实姓名、用户密码、创建日期、更新日期、角色。其中角色根据其在不同项目中的身份改变。

标注项目实体属性包含项目ID、项目名称、项目简介、项目状态、创建时间、更新时间、完成时间。

文档实体属性包含文档ID、文件名、上传时间、更新时间。

标签实体属性包含标签ID、所属项目ID、创建时间、更新时间、标签关键字、标签名称。

标注结果实体属性包含标注ID、标注内容、任务评价、标注位置、起始位置、结束位置、创建时间、更新时间。

实体属性E-R图如图4.1所示：




图4.1 标注子系统-实体属性图

对于以上实体，在本系统中的关系为：

①管理员用户创建标注项目，该关系为1对n关系。

②标注项目包含标注文档，该关系为1对1关系。

③标注项目包含标签，该关系为1对n关系。

标注项目被分配给多个标注员完成，对应多个标注任务，该关系拆分为关系④⑤。

④标注项目包含标注任务，该关系为1对n关系。

⑤标注员用户完成标注任务生成标注结果，该关系为1对1对n关系。

⑥标注结果对应标签关系，该关系为n对1关系。（一个标注任务完成后会对应多个标注结果）

实体联系E-R图如图4.2所示：




图4.2 标注子系统-实体关系图

4.3.2 逻辑结构设计

本节根据标注系统的概念结构设计，完成逻辑结构设计。

关系①是管理员与标注项目的1对n关系，为简化查询流程，本系统中将管理员用户ID属性添加为标注项目实体的依赖属性。

关系②是标注项目与文档的1对1关系，由于文档难以通过关系型数据库存储，因此文档内容存储在非关系型数据库中，关系型数据库存放文档索引。且本关系中涉及到文档格式转化，单个文档在非关系型数据库中根据不同格式存储为多项，因此在关系型数据库中文档添加索引属性，且该关系使用关系表存储。

关系③是标注项目与标签的1对n关系，为简化查询流程，本系统中将标注项目ID属性添加为标签实体的依赖属性。

关系④是标注员用户、标注项目与标注结果的1：n：n关系，依据该关系，本系统设置标注员用户与标注项目对应关系表annotator，与其扩充表task，并将task表Id属性作为标注结果实体依赖属性。

关系⑤是标注结果与标签的1对1关系，为简化查询流程，本系统中将标签ID属性添加为标注结果实体的依赖属性。

综上所述，标注子系统数据库的逻辑结构设计如下：

表名	表类型	属性			
user	用户实体表	id	username	realName	password
		roles	createdAt	updatedAt	
project	标注项目实体表	id	name	introduction	attachmentl
		attachmentNam	assigned	createdAt	updatedAt
		assignedAt	userId		
ossFile	标注文档实体表	id	filename	objectName	bucket
		createdAt	updatedAt		
label	标注结果实体表	id	taskId	content	remark
		tagId	location	start	end
		creatorId	creatorName	createdAt	updatedAt
tag	标签实体表	id	projectId	tagKey	tagName
		createdAt	updatedAt		
task	标注员用户-标注项目关系表	id	projectId	userId	userRealNar
		paperId	identifier	pdfId	htmlId
		txtId	finished	createdAt	updatedAt
paper	项目-文档关系表	id	projectId	identifier	filename
		pdfId	htmlId	createdAt	updatedAt
		txtId	status		
annotator	标注员用户-标注项目关系表	id	userId	projectId	

表4.1 标注子系统数据库逻辑结构表

4.3.3 物理结构设计

根据标注子系统逻辑结构设计，标注子系统数据库物理结构设计如下：

表 4.2 user表-实体表

字段	类型	存储类型	说明
id	String	varchar	主键;非空
username	String	varchar	用户名;非空
realName	String	varchar	用户姓名;非空
password	String	varchar	用户密码;非空
roles	List<String>	varchar	用户身份;非空

createdAt	Date	Date	创建日期;非空
updatedAt	Date	Date	更新日期;非空

表 4.3 project表-实体表

字段	类型	存储类型	说明
id	String	varchar	主键;非空
name	String	varchar	标注项目名称;非空
introduction	String	varchar	标注项目简介;非空
attachmentId	String	varchar	附件ID;依赖ossFile表主键;非空
attachmentName	String	varchar	附件名称;非空
assigned	String	varchar	分配任务;非空
createdAt	Date	Date	创建日期;非空
updatedAt	Date	Date	更新日期;非空
assignedAt	Date	Date	分配任务日期;非空

表 4.4 ossFile表-实体表

字段	类型	存储类型	说明
id	String	varchar	主键;非空
filename	String	varchar	标注文档名称;非空
objectName	String	varchar	标注项目简介;非空
bucket	String	varchar	文件在其他数据库存储索引;非空
createdAt	Date	Date	创建日期;非空
updatedAt	Date	Date	更新日期;非空

表4.5 paper表-关系表

字段	类型	存储类型	说明
id	String	varchar	主键;非空
projectId	String	varchar	标注项目名称;非空
identifier	String	varchar	文档标识;非空
filename	String	varchar	标注文档名称;非空
pdfId	String	varchar	pdf格式ID;非空
htmlId	String	varchar	html格式ID;非空
createdAt	Date	Date	创建日期;非空
updatedAt	Date	Date	更新日期;非空
txtId	String	varchar	txt格式ID;非空
status	enum	enum	三个状态，等待标注、标注成功、标注失败;非空

表4.6 annotator表-关系表

字段	类型	存储类型	说明
id	String	varchar	主键;非空
projectId	String	varchar	标注项目名称;非空;依赖project表
userId	String	varchar	标注员ID;非空;依赖user表

表4.7 tag表-实体表

字段	类型	存储类型	说明
----	----	------	----

id	String	varchar	主键;非空
projectId	String	varchar	标注项目名称;非空;依赖project表
tagKey	String	varchar	标签关键字;非空
tagName	String	varchar	标签名;非空;依赖user表
createdAt	Date	Date	创建日期;非空
updatedAt	Date	Date	更新日期;非空

表4.8 task表-关系表

字段	类型	存储类型	说明
id	String	varchar	主键;非空
projectId	String	varchar	标注项目名称;非空;依赖project表
userId	String	varchar	标签关键字;非空
userRealName	String	varchar	标签名;非空;依赖user表
paperId	String	varchar	非空;依赖paper表
identifier	String	varchar	文档标识;非空
pdfId	String	varchar	PDF格式ID;非空
htmlId	String	varchar	html格式ID;非空
txtId	String	varchar	txtx格式ID;非空
finished	boolean	boolean	标注任务是否完成;非空
createdAt	Date	Date	创建日期;非空
updatedAt	Date	Date	更新日期;非空

表4.9 label表-实体表

--	--	--	--

字段	类型	存储类型	说明
id	String	varchar	主键;非空
taskId	String	varchar	任务ID;非空;依赖task表
content	String	varchar	任务内容
remark	String	varchar	任务评价
tagId	String	varchar	标记ID;依赖tag表
location	String	varchar	标注位置;非空
start	integer	int	开始位置;非空
end	integer	int	结尾位置;非空
creatorId	String	varchar	标注员ID;非空
creatorName	String	varchar	标注员名称;非空
createdAt	Date	Date	创建日期;非空
updatedAt	Date	Date	更新日期;非空

5 挖掘子系统功能设计

5.1 系统类图

系统整体的类图如下图5.1所示。




图5.1 系统类图

5.2 挖掘子系统功能设计

5.2.1 文档上传

功能整体概述：

系统提供文档上传功能，支持用户根据自己的需求上传需要修改的文档，同时系统支持自动转换格式功能。

涉及类详细介绍：

文档上传功能主要涉及的类的属性和方法的详细介绍分别如表5.1所示。

表5.1 文档上传功能主要涉及类方法详细介绍

涉及类/接口	方法名	
PaperContro ller	public ResultModel<Void> uploadPaper(@RequestParam String projectId, @RequestParam MultipartFile[] files)	上传文
OssFileServi ce	OssFile uploadPdfFile(MultipartFile file);OssFile uploadHtmlFile(File file);OssFile uploadTxtFile(File file);	文档格

5.2.2 模型选择

功能整体概述：

我们为用户提供了三种模型选择方式，第一种是预设模型选择即选择系统内置模型，第二种是社区共享模型选择，选择用户自己分享至社区供其他用户自由使用的模型，第三种方式是直接调用第三方接口如Chatgpt等。在本系统我们实现调用接口的方式。

表5.2模型上传功能主要涉及类方法详细介

涉及类/接口	方法名	说明
ExtractClient	public interface ExtractClient	调用信息提 取接口
ExtractClien tFallback	public JSONObject getParam(ParamRequestDTO paramRequestDTO)	通过接口获 取提取后信 息
ParagraphClie nt	public interface ParagraphClient	调用段落提 取接口
ParagraphClie ntFallback	getParam(ParagraphRequestDTO	取提取后的

5.2.3 信息提取

功能整体概述：

模型可以根据用户需求提取段落标注信息，以及关键的数据。为实现此功能，主要涉及的类属性和类方法如表5.3所示

表5.3信息提取功能主要涉及类方法详细介绍

涉及类/接口	方法名	说明
ExtractContr oller	public ResultModel<List<ExtractResultVO>> listByTask(@RequestParam String taskId), public ResultModel<List<ExtractRecordVO>> listRecordByTask(@RequestParam String taskId)	模型进行信 息提取
ParagraphC ontroller	public ResultModel<List<Paragraph>> listByProject(@RequestParam String projectId)	管理段落提 取信息
ProjectControl ler	public ResultModel<Project> createProject(@RequestBody ProjectInfoDTO projectInfoDTO), public ResultModel<Void> updateProject(@RequestParam String id, @RequestBody ProjectInfoDTO projectInfoDTO)	管理任务信 息
TaskController	public ResultModel<Task> createTask(@RequestBody TaskInfoDTO taskInfoDTO)	创建提取任 务信息

5.3 数据库设计

5.3.1 概念结构设计

数据库整体E-R图如下图5.1所示：

图5.1 数据库整体E-R图

5.3.2 逻辑结构设计

系统数据库中包含的数据库表如表5.1所示。

表5.1 系统数据库表

序号	表名 (英文)	说明
1	user	用户信息表
2	resource	诗词对联资源信息表
3	poem	唐诗信息表
4	ci	宋词信息表
5	couplet	对联信息表
6	author	作者信息表
7	collection	收藏信息表
8	feedback_info	反馈信息表
9	model	模型信息表
10	log	日志信息表

5.3.3 用户信息表

用户信息表用于存储用户的基本信息，如表5.2所示。

表5.2 用户信息表

Table 5.2 user

字段名称	字段说明	数据类型	是否主键	是否外键	是否允许为空
user_id	用户ID	VARCHAR(32)	是	否	否
user_regist_time	用户注册时间	DATETIME	否	否	否
user_account	用户账号	VARCHAR(32)	否	否	否
user_password	用户登录密码	VARCHAR(32)	否	否	否
user_nickname	用户昵称	VARCHAR(32)	否	否	是
user_update_time	用户更新时间	DATETIME	否	否	否
user_question	用户密保问题	VARCHAR(255)	否	否	否
user_answer	用户密保答案	VARCHAR(255)	否	否	否
user_role	用户角色	VARCHAR(32)	否	否	否
user_portrait	用户头像	VARCHAR(255)	否	否	是
user_email	用户邮箱	VARCHAR(32)	否	否	是
user_phone	用户手机号	VARCHAR(20)	否	否	是
user_is_auth	用户认证状态	VARCHAR(1)	否	否	是
user_status	用户状态	VARCHAR(1)	否	否	是

6 用户界面设计

照着挖掘系统已有的页面，设计原型图：

- <http://ye-sun.com:1853>
- <http://ye-sun.com:1852>

6.1 注册和登录界面

×

≡ register (2 of 4)

100% ▾

☰ ⚡ ⋮

axure

欢迎使用

智能文本标注与挖掘系统

已有账号？

去登录

用户名

Helper Text

姓名

Helper Text

密码

Helper Text

确认密码

Helper Text

注册

欢迎使用 智能文本标注与挖掘系统

没有账号? [立即注册](#)

用户名

Helper Text

密码

Helper Text

登陆

6.2 个人信息管理界面



Edit

Full Name

Julia Ray

Job Title

Research Assistant

Company

Trident Logistics Inc.

Email Address

jray48@gmail.com

个人设置

标注设置

挖掘设置

First Name*

Last Name*

Email Address*

Phone Number

Date of Birth

MM

/

DD

/

YYYY

Placeholder text on Tab 1

Country / Region

Street Address

City

State / Province

ZIP / Postal

Save

6.3 挖掘主界面

挖掘系统 标注系统

历史 1
历史 2
历史 3
...



智能文本标注与挖掘系统

选择大模型



Claude-3: Anthropic 最智能的模型，能够处理复杂分析。



GPT-4: Anthropic最智能的模型，能够处理复杂分析。



Llama 3 8b: Meta的开源大模型。在本地服务器部署，具有更高的隐私保护。

选择实体挖掘预设



材料科学: 挖掘文献中的化学实体，反应时间，反应条件等。



科研文献: 挖掘文献中的相关工作，假设，超参数等。



短篇小说: 挖掘小说中的人物，关系，事件，线索等。

Try typing 'new'



6.4 挖掘文件上传

挖掘系统 标注系统

历史 1
历史 2
历史 3
...



智能文本标注与挖掘系统



请上传文件，我会找出合成段落并对以下实体进行标注：
 Organic_Linker (有机连接剂) – 指涉及的有机化合物前体，例如 H₂L。
 Metal_Source (金属来源) – 指使用的金属来源，例如钨(III)硝酸盐六水合物。
 Reaction_Time (反应时间) – 反应所需的时间，例如48小时。
 Reaction_Temperature (反应温度) – 反应进行的温度，例如70°C



DAFormer A Smart En...
PDF, 8.94 MB



以下是合成段落：“Compound 3: A solution of H₂L (10.1 mg, 0.025 mmol) and samarium(III) nitrate hexahydrate (22.2 mg, 0.050 mmol) in DMF (2 mL) and water (0.5 mL) was prepared and then transferred to a 8 mL glass vessel, which was sealed and heated at 70°C for 48 h (solvolothermal reactor). Cooling of the solution to room temperature afforded colorless crystals of 3. elemental analysis calcd (%) for C₂₇H₂₉N₆O₁₂Sm (779.91): C41.58, H 3.75, N10.78; found: C41.43, H3.20, N10.34”。是否对其进行实体标注？

Try typing 'new'



6.5 挖掘结果展示

历史 2

历史 3

...



智能文本标注与挖掘系统



请上传文件，我会找出合成段落并对以下实体进行标注：

Organic_Linker (有机连接剂) – 指涉及的有机化合物前体，例如 H₂L。

Metal_Source (金属来源) – 指使用的金属来源，例如钕(III)硝酸盐六水合物。

Reaction_Time (反应时间) – 反应所需的时间，例如48小时。

Reaction_Temperature (反应温度) – 反应进行的温度，例如70°C



DAFormer A Smart En...

PDF, 8.94 MB





以下是合成段落：*Compound 3:Asolution of H₂L(10.1 mg, 0.025 mmol) and samarium(III) nitrate hexahydrate (22.2 mg, 0.050 mmol) in DMF (2 mL) and water (0.5 mL) was prepared and then transferred to a8mL glass vessel, which was sealed and heated at 708Cfor 48 h(solvothormal reactor). Cooling of the solution to room temperature afforded colorless crystals of 3.elemental analysis calcd (%) for C 27 H 29 N 6 O 12 Sm (779.91): C41.58, H 3.75, N10.78;found:C41.43, H3.20, N10.34*。是否对其进行实体标注？






抽取结果 [export](#)

Compound_Name **ref**

C 27 H 29 N 6 O 12 Sm

Reaction_Time **ref**

48h

Reaction_Temperature

reaction temprature

Metal_Source **ref**

precursor_name : DMF

第七页 第3章 第1段


"Compound 3:Asolution of H₂L(10.1 mg, 0.025 mmol) and samarium(III) nitrate hexahydrate (22.2 mg, 0.050 mmol) in DMF (2 mL) and water (0.5 mL) was prepared and then transferred to a8mL glass vessel, which was sealed and heated at 708Cfor 48 h(solvothormal reactor). Cooling of the solution to room temperature afforded colorless crystals of 3.elemental analysis calcd (%) for C 27 H 29 N 6 O 12 Sm (779.91): C41.58, H 3.75, N10.78;found:C41.43, H3.20, N10.34"




6.6 标注项目创建



6.7 标注项目管理



6.8 标注任务执行

Journal of the Less-Common Metals, 125 (1986) 45 - 57

45

SPECTROSCOPY STUDIES AND CRYSTAL STRUCTURE DETERMINATION OF [Ln(HCOO)₃·2(HCONH₂)] CRYSTALS

J. LEGENDZIEWICZ, T. GŁOWIAK, G. OCZKO and DAO CONG NGOAN
Institute of Chemistry, University of Wrocław, Wrocław (Poland)
(Received April 4, 1986)

Summary

A new method of **synthesis** of Ln³⁺ formate is elaborated. Isomorphic monocrystals of [Ln(HCOO)₃·2FA] (Ln ≡ Er, Dy; FA ≡ (CH₃NO) ≡ (HCONH₂) = formamide) were used for structure determination. The crystals are monoclinic, space group C2 with *a* = 11.200(3) Å, *b* = 7.107(3) Å, *c* = 6.547(2) Å, β = 109.50(4)°, *V* = 491.2 Å³, *Z* = 2, *d_c* = 2.65 g cm⁻³, *d_m* = 2.61 g cm⁻³, μ(Mo Kα) = 89.0 cm⁻¹; *F*(000) = 370 electrons for erbium complex and *a* = 11.301(3) Å, *b* = 7.149(3) Å, *c* = 6.592(2) Å; β = 109.56(4)°, *V* = 501.8 Å³, *Z* = 2, *d_c* = 2.57 g cm⁻³, *d_m* = 2.60 g cm⁻³, μ(Mo Kα) = 77.5 cm⁻¹; *F*(000) = 366 electrons for dysprosium complex.

The final *R* factors were 0.020 and 0.021, while *R_w* = 0.039 and 0.032 for erbium and dysprosium complexes respectively. The coordination polyhedron of Ln³⁺ ions comprises six oxygen atoms from formate ions and two oxygen atoms from formamide molecules. The polymers are made up of

使用说明 偏好设置 继续标注

数据 统计

标注内容	标签	备注
synthesis	metric	
monocrystals of carboxylate,	method	

共 2 项数据

10 条/页

<

1

>

使用说明

按住鼠标左键在标注文本中滑动选择标注词。

1/7

跳过且不再展示

下一步